

# HW #1

1910030 박근아

먼저 손계산으로 가치 반복 알고리즘을 수행할 수 있다.

무슨  $t=0$  인 경우 모든 상태를 0으로 초기화해준다.

그리고  $t=1$  일 때 우선 목표자점에 인접한 15칸 칸에서 알고리즘을 적용해보자.

(각 행층은 앞글자를 따서 L, D, R, U 으로 표현한다, stochastic  $P=1$ )

$$\begin{aligned} V^{(1)}(15) &= \max \{ P(11, 0 | 15, U)(0 + V^{(0)}(11)), P(16, 1 | 15, R)(0 + V^{(0)}(16)), \\ &\quad P(14, 0 | 15, L)(0 + V^{(0)}(14)), P(15, 0 | 15, D)(0 + V^{(0)}(15)) \} \\ &= \max \{ 0, 1, 0, 0 \} = 1 \end{aligned}$$

$$\therefore A(15) = \{ \text{Right} \}$$

H에서는 이동이 일어날 수 없으므로 제외하고 각 칸에서 알고리즘을 적용해보면 다음과 같다.

$$\begin{aligned} V^{(1)}(1)=0, V^{(1)}(2)=0, V^{(1)}(3)=0, V^{(1)}(4)=0, V^{(1)}(5)=0, V^{(1)}(7)=0 \\ V^{(1)}(9)=0, V^{(1)}(10)=0, V^{(1)}(11)=0, V^{(1)}(13)=0, V^{(1)}(14)=0 \end{aligned}$$

이어서 2번째 반복을 수행한다. 이전 결과에 이어서 대부분의 칸의 값은 0 이고 15칸과 근처값들만 다시 구해본다.

$$V^{(2)}(11) = \max \{ 1 \times (0 + V^{(1)}(15)), 0, 0, 0 \} = 1, A(11) = \{ \text{Down} \}$$

$$V^{(2)}(14) = \max \{ 1 \times (0 + V^{(1)}(15)), 0, 0, 0 \} = 1, A(14) = \{ \text{Right} \}$$

$$V^{(2)}(15) = \max \{ 0, 0, 1, 1 \} = 1, A(15) = \{ \text{Down, Right} \}$$

→ 보드 밖으로 나간 패드 보상은 0이며 제자리에 머물기 때문에 행층이 추가된다.

3 번째 반복에 이르러 각 칸에서의 가치함수를 구해준다.

$$V^{(3)}(10) = 1, A(10) = \{ \text{Down, Right} \}$$

$$V^{(3)}(13) = 1, A(13) = \{ \text{Right} \}$$

$$V^{(3)}(7) = 1, A(7) = \{ \text{Down} \}$$

$$V^{(3)}(11) = 1, A(11) = \{ \text{Down} \} / V^{(3)}(14) = 1, A(14) = \{ \text{Down, Right} \}$$

$$V^{(3)}(15) = 1, A(15) = \{ \text{Down, Right, Left, Up} \}$$

→ 인접 칸의 보상이 커짐에 따라 행층이 추가된다.

0	0	0	0
0	0	0	0
0	0	0	0
0	0	0	0

$t=0$

S	F	F	F
F	H	F	H
F	F	F	H
H	F	F	G

S	0	0	0
0	H	0	H
0	0	0	H
0	0	1	G

$t=1$

S	0	0	0
0	H	0	H
0	0	1	H
0	1	1	G

↕	↕	↕	↕
↕		↕	
↕	↕	↓	
↕	→	↘	

$t=2$

↕	↕	↕	↕
↕		↓	
↕	↘	↓	
→	↘	↕	

S	0	0	0
0	H	1	H
0	1	1	H
1	1	1	G

$t=3$

4 번째 반복기까지 각 칸에서의 가치함수를 구해준다.

$$V^{(4)}(10) = 1, A(10) = \{ \text{Down, Right} \}$$

$$V^{(4)}(13) = 1, A(13) = \{ \text{Right, Down, Left} \}$$

$$V^{(4)}(7) = 1, A(7) = \{ \text{Down} \}$$

$$V^{(4)}(11) = 1, A(11) = \{ \text{Down, Left, Up} \}$$

$$V^{(4)}(14) = 1, A(14) = \{ \text{Down, Right, Left, Up} \}$$

$$V^{(4)}(15) = 1, A(15) = \{ \text{Down, Right, Left, Up} \}$$

$$V^{(4)}(3) = 1, A(3) = \{ \text{Down} \} / V^{(4)}(9) = 1, A(9) = \{ \text{Down, Right} \}$$

↕	↕	↓	↕
↕		↓	
↗	↗	↕	
↕	↕	↕	

S	0	1	0
0	H	1	H
1	1	1	H
1	1	1	G

t=4

마지막으로 반복을 진행하면 다음과 같다.

$$V^{(5)}(2) = 1, A(2) = \{ \text{Right} \} / V^{(5)}(4) = 1, A(4) = \{ \text{Left} \}$$

$$V^{(5)}(5) = 1, A(5) = \{ \text{Down} \}$$

t=4과 비교해 행동의 종류가 같아지는 경우는 또한 다음과 같다.

$$V^{(5)}(10) = 1, A(10) = \{ \text{Down, Right, Left} \} / V^{(5)}(3) = 1, A(3) = \{ \text{Down, Up} \}$$

$$V^{(5)}(13) = 1, A(13) = \{ \text{Down, Right, Left, Up} \} / V^{(5)}(7) = 1, A(7) = \{ \text{Down, Up} \}$$

$$V^{(5)}(9) = 1, A(9) = \{ \text{Down, Right, Left} \}$$

↕	→	↓	←
↓		↕	
↔	↔	↕	
↕	↕	↕	

0	1	1	1
1	H	1	H
1	1	1	H
1	1	1	0

t=5

이제 실제 코드를 실행한 결과는 다음과 같고 결과를 표현한 그림은 오른쪽과 같다.

```
In [14]: optimal_policy = extract_policy(optimal_value_function, gamma=1.0)
```

```
1.0
2.0
0.0
3.0
0.0
0.0
0.0
3.0
1.0
0.0
0.0
2.0
1.0
0.0
```

```
print(optimal_policy)
```

```
In [15]: print(optimal_policy)
```

```
[1. 2. 0. 3. 0. 0. 0. 3. 1. 0. 0. 2. 1. 0.]
```

↓	→	←	↑
←	←	←	←
↑	↓	←	←
←	→	↓	←

손계산한 결과와 비교하면 반복횟수를 고정했을 때, 손계산한 결과는 goal이

조각하는 보상을 확인할 수 있고 그 경로 역시 코드에 비해

조금 더 직관적으로 확인할 수 있다.

↕	→	↓	←
↓		↕	
↔	↔	↕	
↕	↕	↕	